

计算机工程与应用
Computer Engineering and Applications
ISSN 1002-8331,CN 11-2127/TP

《计算机工程与应用》网络首发论文

题目：　多层次特征融合的中文医疗命名实体识别
作者：　刘纳，刘磊，吴克东，季喆，马宜静
网络首发日期：　2026-03-16
引用格式：　刘纳，刘磊，吴克东，季喆，马宜静．多层次特征融合的中文医疗命名实体识别[J/OL]．计算机工程与应用.
https://link.cnki.net/urlid/11.2127.TP.20260316.0934.004



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

网络首发时间：2026-03-16 13:50:06　网络首发地址：https://link.cnki.net/urlid/11.2127.TP.20260316.0934.004

多层次特征融合的中文医疗命名实体识别

刘纳[1,2+]，刘磊[1,2]，吴克东[1,2]，季喆[1,2]，马宜静[1,2]

1.北方民族大学 计算机科学与工程学院，银川　750021
2.北方民族大学 图像图形智能处理国家民委重点实验室，银川　750021
+ 通信作者 E-mail：liuna@nun.edu.cn

摘要：针对中文医疗命名实体识别任务面临数据稀缺与实体结构复杂等挑战，传统模型在嵌套实体识别与边界模糊场景下性能受限。因此，本研究提出一种多层次特征融合模型。该模型首先基于 MC-BERT 医疗预训练表征实现语义增强，并通过协同融合全局与局部特征以增强跨维度特征交互，从而提升对实体层次结构的语义感知能力。最后设计协同旋转指针网络以精准定位实体边界。通过语义增强、结构感知与边界检测三重机制协同作用，显著提升了实体识别性能。实验结果表明，与 BERT-BiLSTM-CRF 方法相比，该模型在 CMeEE-V2、IMCS-V2 和 CMeIE-V2 三个中文医疗数据集上的 F1 值分别提升了 12.75%、8.06%和 4.46%。此外，在中文通用领域 Weibo 数据集上的 F1 值提升了 16.75%，有效验证了模型的泛化能力。

关键词：医疗文本挖掘；命名实体识别；多层次特征融合；预训练语言模型

文献标志码:A　中图分类号:TP391.1　doi：10.3778/j.issn.1002-8331.2507-0353

Chinese Medical Named Entity Recognition with Multi-Level Feature Fusion

LIU Na[1,2+]，LIU Lei[1,2]，WU Kedong[1,2]，JI Zhe[1,2]，MA Yijing[1,2]

1. College of Computer Science and Engineering, North Minzu University,Yinchuan 750021, China
2. The Key Laboratory of Images and Graphics Intelligent Processing of State Ethnic Affairs Commission, North-Minzu University,Yinchuan 750021, China

Abstract：For Chinese medical named entity recognition task, the traditional model has limited performance in nested entity recognition and fuzzy boundary scenarios due to data scarcity and complex entity structure. Therefore, this study proposes a multi-level feature fusion model. The model firstly implements semantic enhancement based on MC-BERT medical pre-training representation, and enhances cross-dimensional feature interaction through collaborative fusion of global and local features, so as to improve semantic perception ability of entity hierarchy. Finally, a cooperative rotation pointer network is designed to accurately locate the boundary of the entity. Through the triple mechanism of semantic enhancement, structure perception and boundary detection, the performance of entity recognition is significantly improved. Experimental results show that compared with BERT-BiLSTM-CRF method, the F1 values of this model on CMeEE-V2, IMCS-V2 and CMeIE-V2 Chinese medical datasets are improved by 12.75%, 8.06% and

基金项目：国家自然科学基金资助项目(62162001)；宁夏重点研发计划引才专项项目(2024BEH04020)；北方民族大学校级科研项目(2024XYZJK01)；北方民族大学研究生创新项目(YCX24374)。

作者简介：刘纳(1986—)，女，博士，讲师，CCF 会员，主要研究方向为数据挖掘、自然语言处理；刘磊(1999—)，男，硕士研究生，CCF 学生会员，主要研究方向为数据挖掘；吴克东(1997—)，男，硕士研究生，CCF 学生会员，主要研究方向为数据挖掘；季喆(2000—)，男，硕士研究生，CCF 学生会员，主要研究方向为数据挖掘；马宜静(1997—)，女，硕士研究生，主要研究方向为数据分析。

4.46% respectively. In addition, the F1 value on Weibo dataset in Chinese common domain increased by 16.75%, which effectively verified the generalization ability of the model.

Key words：medical text mining; named entity recognition; multi-layer feature fusion; pre-trained model

随着移动互联网、人工智能与大数据技术的深度融合，智慧医疗正不断重塑传统医疗服务模式。我国互联网医疗规模持续扩大，在线医疗服务平台显著提升了医疗资源的可及性与服务效率。然而，目前大量医疗数据仍以非结构化文本形式存在[1]，其中蕴含的丰富医疗知识难以被机器直接理解与利用。命名实体识别(Named Entity Recognition, NER)作为自然语言处理领域的基础任务，旨在从文本中自动提取疾病、药物、手术等关键医学实体[2]，其识别性能直接影响智慧医疗系统的知识理解与语义推理能力。

中文医疗命名实体识别任务面临数据稀缺、文本结构复杂以及嵌套实体普遍存在等挑战。由于中文缺乏显式的词边界标识，实体识别过程必须依赖深层语义理解与上下文推理能力。同时，医疗文本中专业术语密集、语义歧义性强，进一步增加了模型对复杂实体结构的解析难度。传统模型在应对复杂实体语义与结构特征时，性能往往受限。因此，如何构建一种能够融合深层语义信息与结构感知能力的中文医疗实体识别模型，已成为该领域的关键问题。

近年来，基于深度学习的 NER 方法取得了显著进展。例如，Ke 等人[3]采用双向长短记忆网络(Bi- directional Long Short-Term Memory Network, BiLSTM)提升了中文电子病历中的医学实体识别效果。Zhang 等人[4]提出 Lattice-LSTM 模型融合字与词典信息，增强中文语义建模能力。然而，此类方法存在计算效率较低、跨领域泛化能力不足等问题。Devlin 等人[5]提出的 BERT 模型基于自注意力机制，能够有效捕捉上下文中的长距离依赖，在多项 NER 任务中实现突破。后续研究中，Hou 等人[6]提出 Dyn-Att Net 架构进一步优化 BERT-BiLSTM-CRF 框架，在中医实体识别任务上实现性能提升。然而，BERT 在处理中文医疗文本时仍面临句式灵活、语序敏感和字符组合复杂等挑战，这对模型的语义表征能力提出了更高要求，从而影响其在医疗领域 NER 任务中的表现。

综上，现有中文医疗 NER 方法在特征交互与结构建模方面仍有不足。在特征融合层面，模型普遍依赖拼接或加权等浅层操作，缺乏深度交互建模，从而制约对复杂医疗术语的深层语义理解。在结构建模层面，传统方法往往将实体边界识别与类别判定割裂处理，缺失对医学实体间深层结构依赖的有效建模，导致模型在识别嵌套和不连续等复杂结构实体时泛化能力受限。为了解决上述问题，本研究提出了一种多层次特征融合模型(Multi-Level Feature Fusion Model, MLFM)。主要贡献如下：

(1) 构建一种融合全局与局部语义的特征提取框架，提出位置感知的二阶特征交互模块，以建立多源特征之间的深层关系。

(2) 设计双轨卷积架构优化词-字符网格表示，并利用细粒度增强模型对专业术语和复合词的建模能力。

(3) 构建结构感知联合推理模块，通过多层感知机强化局部上下文表征，并与旋转指针网络的边界建模能力协同优化，提升实体解码性能。

(4) 在 CMeEE-V2、IMCS-V2 和 CMeIE-V2 三个中文医疗命名实体识别数据集以及中文通用领域命名实体识别数据集 Weibo 上进行了实验，验证所提方法的有效性。

1 相关工作

医疗领域的命名实体识别在整体框架上与通用领域相似。传统方法依赖人工构建的规则与词典，通过规则匹配和专业术语表进行识别，尽管在特定场景下精度较高，但泛化能力有限，难以应对医疗文本复杂多变的语言表达。随着深度学习的发展，医疗 NER 研究取得显著进展，成为当前研究热点。现有中文医疗 NER 方法主要分为基于神经网络结构、多层次任务学习、迁移学习及混合结构四类[7]，其中卷积神经网络(Convolutional Neural Network, CNN)、BiLSTM 与 Transformer 架构被广泛应用于特征提取与语义建模。早期，Collobert 等人[8]首次将 CNN 引入 NER 任务，用于自动捕捉局部特征，推动深度学习在实体识别中的应用。随后，曹依依等人[9]提出基于迭代扩张卷积的 CNN 模型，以提取多尺度语义特征，增强局部实体识别能力。但 CNN 聚焦局部上下文，缺乏对全局依赖的建模能力，难以处理长距离语义关系。Tang 等人[10]构建 BERT-BiLSTM-Attention-CRF 多层架构，通过串行堆叠多个特征提取与优化模块，在中文 NER 任务中实现性能提升。然而，此类方法本质上仍属于特征的层级堆叠，不同模块间缺乏协同交互机制，阻碍特征的

深度融合。Leng 等人[11]进一步提出 DABC 模型，在 BERT-BiLSTM-CRF 基础上引入多头注意力机制与增强型解码策略，加强特征表达与长距离语义建模。尽管在信息筛选上表现优异，但在局部建模、词边界识别及字符语义消歧方面仍存在不足。为进一步提升实体识别效果，林令德等人[12]提出一种多层动态融合模型，该模型融合预训练模型的底层表层特征、中层句法结构特征与高层语义信息，并结合条件随机场进行联合解码，有效提升医疗命名实体识别的准确性与鲁棒性。周文卓等人[13]提出 RBIEGP 模型，结合生物医学语料训练的 RoBERTa、BiGRU 与扩张卷积网络，通过全局指针机制实现实体识别。此外，Zhang 等人[14]提出 VisPhone 模型，将部首、字符和词汇等多粒度信息与语音、视觉特征融合，提升了模型的上下文语义理解能力。尽管上述方法在多层次语义特征融合方面取得了一定进展，但多数模型仍停留在对上下文、局部与全局特征的简单拼接或加权融合，缺乏对多层语义间潜在依赖的深度建模，限制其在复杂实体识别任务中的表现。

另一个研究趋势是结合嵌套命名实体的层次特性，将任务转化为词对边界识别问题，该类方法通过设计头尾指针机制分别标注实体的起始与结束位置，并融合多种特征策略，以实现对实体的精确定位与分类。Zheng 等人[15]提出边界感知模型，先利用序列标注识别实体候选边界以定位实体，再基于边界信息完成类别预测。Li 等人[16]发现边界识别与类型判定具有互补性，提出基于双仿射机制的模块化交互网络(MIN)，实现信息共享与协同增强。Su 等人[17]提出的 Global Pointer 采用多头并行机制处理多实体识别任务，通过为每个类型构建独立决策空间实现分类。虽然该方法通过相对位置编码增强特征表征，但不同类型识别路径间的信息壁垒限制了跨类型协同推理能力。这导致其在处理结构依赖实体时表现受限，且可能引发边界预测冲突。Han 等人[18]提出一种融合分割感知边界建模与关系图卷积网络的嵌套命名实体识别模型，并通过多层 CRF 有效缓解了嵌套实体识别中的错误传播问题。Yu 等人[19]基于图依赖解析框架，通过 BiLSTM 提取上下文特征，利用双前馈神经网络分别建模实体的起始与终止边界表示，并通过 Bi-affine 模型对实体进行预测。Li 等人[20]通过构建基于跨度的实体片段关系图，并在解码阶段寻找完整子图，从而实现对不连续实体的识别。Zhang 等人[21]提出远程监督策略，利用词典匹配自动构建训练数据，并通过样本重加权结合因果不变正则化来减轻词典偏差对模型性能的影响。Li 等人[22]提出多层次语义增强框架，通过实体数据增强、边界模糊策略和改进蒸馏加权方法，提升自蒸馏 BERT 在中文 NER 任务中的泛化能力。然而，上述方法在识别嵌套实体的过程中，都未考虑在医疗文本特定领域下实体与实体之间存在着不同类别嵌套的限制，例如复杂术语协同困难、嵌套及不连续实体识别不足、专业知识适应性有限等问题。

针对现有方法在特征融合与结构建模方面的局限，该研究提出多层次特征融合与结构感知联合推理模型。在特征融合层面，设计位置感知动态交互模块，通过显式二阶交互建立多层语义特征的结构化关联，实现由被动组合向主动构建的结构转变。在结构推理层面，在词对表示中引入卷积优化机制，提出旋转指针网络与多层感知机协同框架，通过端到端联合推理将边界识别与类型判定统一建模，从而缓解传统方法的决策割裂问题。该模型显著提升复杂医疗术语的语义感知能力，并增强对嵌套与不连续实体的识别性能与泛化能力。

2 模型与方法

2.1 模型概述

该研究提出的 MLFM 模型，通过多层次特征提取与交互融合，以提升序列标注任务中语义与结构信息的建模能力。在该模型中，输入序列为 $X=\{x_1,x_2,\cdots,x_n\}$，其中 n 为序列长度，每个字符 x_i 对应一个标签 y_i，标签集合包含{B-sym,I-sym,E-sym,O,S-dis,B-dis,⋯}。其中 B-、I-、E-、S-和 O 分别表示实体边界的开始、中间、结束、单个字符实体以及其他类型。“sym”和“dis”分别表示症状与疾病实体。实体识别任务被建模为序列标注问题，其目标是根据输入序列 X 预测对应的标签序列 Y。

MLFM 模型的整体框架如图 1 所示，主要包含多层次特征提取模块、特征交互模块、卷积优化模块和联合推理四个部分。各模块协同工作，共同应对中文医疗命名实体识别中的复杂挑战。首先，多层次特征提取模块基于注入医疗知识的 MC-BERT 生成高质量字符向量。在此基础上，本模型结合 BiLSTM 提取全局特征，并利用 CharCNN 获取字符级局部特征，最终形成多粒度特征表示。其次，特征交互模块引入位置感知因子分解机(Regional Position-Aware Factorization Machine, RPEFM)，实现不同层次特征的动态交互与融合，从而强化特征间的语义关联。本研究采用卷积优化模块构建卷积运算单元以对词对网格表示进行结构优化，有效增强模型对实体间语义关系的建模能力。

最后，联合推理模块融合旋转指针网络(Rotary Pointer Network, RPN)与多层感知机(Multi-Layer Perceptron, MLP)，通过协同优化实体边界定位与类别判定，从而显著提升对嵌套与不连续等复杂实体的识别性能，最终输出最优预测序列。

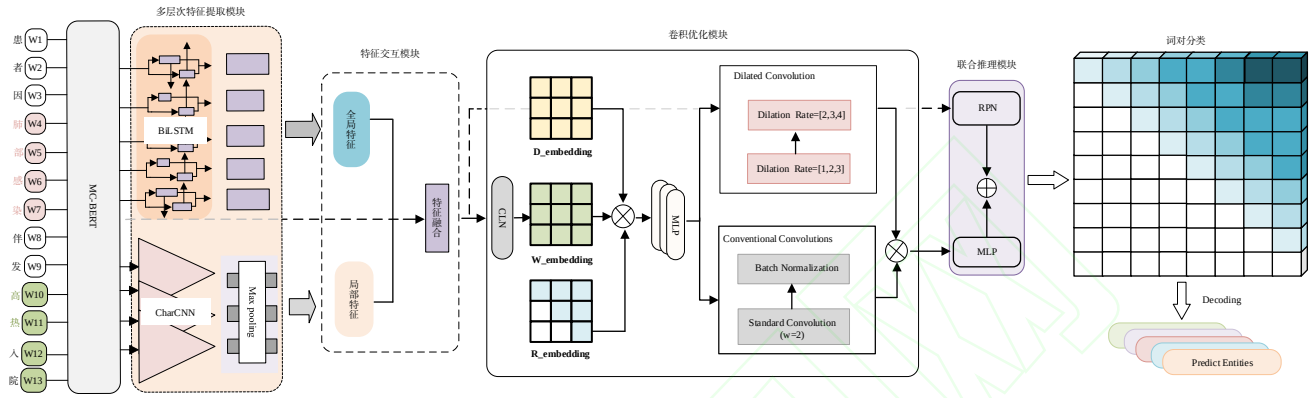


图 1 MLFM 整体模型结构

Fig.1 MLFM Overall Model Structure

2.2 多层次特征提取

本模型采用多层次特征提取机制，利用注入医学知识的 MC-BERT 进行预训练编码，并结合序列特征提取方法，全面捕捉医疗文本中的语义与结构信息。MC-BERT 基于 BERT 架构，区别于传统的全词掩码策略，采用全实体掩码(Whole Entity Masking)和全跨度掩码(Whole Span Masking)机制，能更有效地对医疗实体(如“头痛”)及医疗短语(如“头部隐隐作痛”)进行掩码，以融合医疗实体知识与通用语言知识，从而增强语义理解能力。在模型输入端，输入序列首尾分别添加特殊标记[CLS]与[SEP]，并通过填充[PAD]标记将序列统一至最大长度。处理后的序列输入 MC-BERT 编码器，以生成每个字符的上下文隐藏层表示，计算公式如(1)所示:

$$\boldsymbol{e}_i = MC-BERT(x_i) \tag{1}$$

其中，$\boldsymbol{e}_i$表示经过 MC-BERT 编码后得到对应x_i语义向量表示，x_i表示句子中的第 i 个字符。

在 MC-BERT 生成的字符向量基础上，本研究通过 BiLSTM 提取全局特征，以捕获序列中的长距离依赖关系，从而有效提升实体边界判定与类型识别的准确性。BiLSTM 由两个独立的 LSTM 单元组成，每个单元通过遗忘门、输入门和输出门调控信息流，从而有效缓解梯度消失问题。BiLSTM 分别以时间的正序和逆序对输入序列进行处理。将两个方向的隐藏状态拼接后，可获得句子的全局上下文表示，从而实现更丰富的语义特征建模。计算公式如(2)-(4)所示：

$$\vec{\boldsymbol{h}}_i = LSTM_{forward}(\boldsymbol{e}_i) \tag{2}$$

$$\overleftarrow{\boldsymbol{h}}_i = LSTM_{backward}(\boldsymbol{e}_i) \tag{3}$$

$$\boldsymbol{h}_i = [\vec{\boldsymbol{h}}_i; \overleftarrow{\boldsymbol{h}}_i] \tag{4}$$

其中，$\vec{\boldsymbol{h}}_i$和$\overleftarrow{\boldsymbol{h}}_i$分别表示第 i 个字符正序和逆序 LSTM 的隐藏状态，$\boldsymbol{h}_i$表示拼接后的全局特征向量。

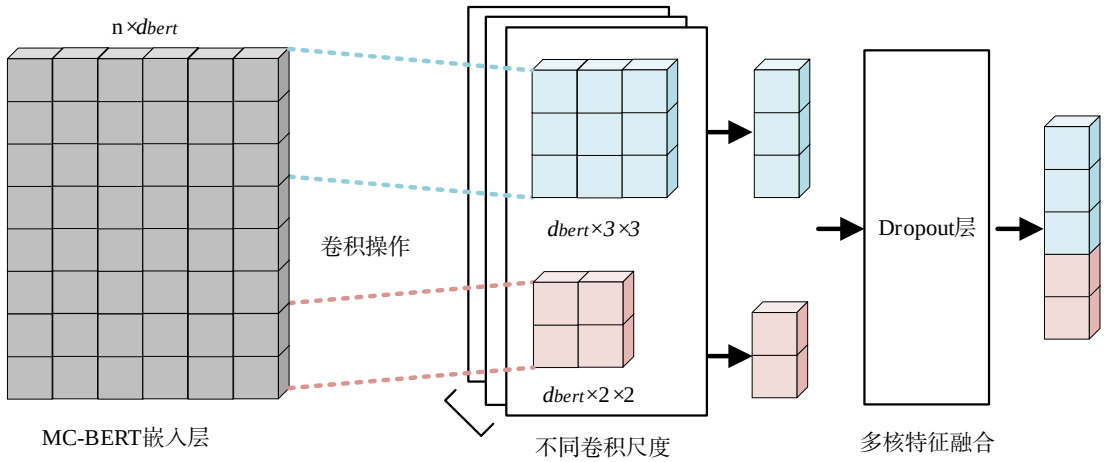


图 2 CharCNN 网络结构图

Fig.2 CharCNN Network Structure Diagram

本模型采用字符卷积神经网络(Character-Level Convolutional Neural Network, CharCNN)提取局部特征，其结构如图 2 所示。CharCNN 以 MC-BERT 输出的向量表示$\boldsymbol{E}=\{\boldsymbol{e_1},\boldsymbol{e_2},\ldots,\boldsymbol{e_n}\}$作为输入，利用多尺度一维卷积核$\boldsymbol{H}\in\mathbb{R}^{d_{bert}\times w}$提取不同 *n-gram* 特征，并融合多尺度卷积的输出，最终形成局部特征表示。模型在训练过程中引入 *Dropout* 机制以防止过拟合，从而增强对医疗复合词和专业术语的识别能力。对于序列中的第 k 个字符，其嵌入矩阵表示为$\boldsymbol{W_k}\in\mathbb{R}^{d_{bert}\times(l+2)}$，其中 l 为文本长度，为保留边界信息，在首尾添加特殊标记，为方便批处理，再通过零填充将其统一至批次内的最大序列长度。经卷积操作后生成的特征图表示为 $\boldsymbol{f_k}\in\mathbb{R}^{l-w+1}$，其第 i 个元素的计算公式如(5)所示:

$$\boldsymbol{f_k}[i]=\tanh(\langle \boldsymbol{W_k}[:,i:i+w-1],\boldsymbol{H}\rangle+b) \tag{5}$$

其中，$\boldsymbol{f_k}[i]$表示字符 k 对应特征图 $\boldsymbol{f_k}$ 中的第 i 个元素，$\boldsymbol{W_k}[:,i:i+w\text{-}1]$表示嵌入矩阵 $\boldsymbol{W_k}$ 的第 i 列到第 $i+w$-1 列的子矩阵，w 为卷积核在序列维度上的窗口宽度，$<A,B>=Tr(AB^T)$为 *Frobenius* 内积，用于衡量卷积核 $\boldsymbol{H}$ 与嵌入矩阵子块之间的相似度，b 为偏置项。

为提取关键信息，对特征图 $\boldsymbol{f_k}$ 中的所有元素 $f_k[i]$ 进行最大池化操作，得到特征 $\boldsymbol{y_k}$，该特征表示卷积核在词 k 上提取的核心语义特征。计算公式如(6)所示：

$$\boldsymbol{y_k}=\max_i \boldsymbol{f_k}[i] \tag{6}$$

该模块引入多个卷积核 $\boldsymbol{H_1},\boldsymbol{H_2},\cdots,\boldsymbol{H_n}$ 分别提取不同尺度的局部特征，并将各卷积核对应的输出结果拼接，得到字符 k 的最终表示向量$\boldsymbol{C_K}=[\boldsymbol{c_k^1};\boldsymbol{c_k^2};\ldots;\boldsymbol{c_k^h}]$。

2.3 特征交互模块

在传统 NER 模型中，不同模块提取的全局与局部特征通常仅通过简单的拼接或加权相加进行融合，缺乏深层次的交互建模机制。而在 NER 任务中，词语间的位置与顺序信息对识别复杂实体尤为关键。

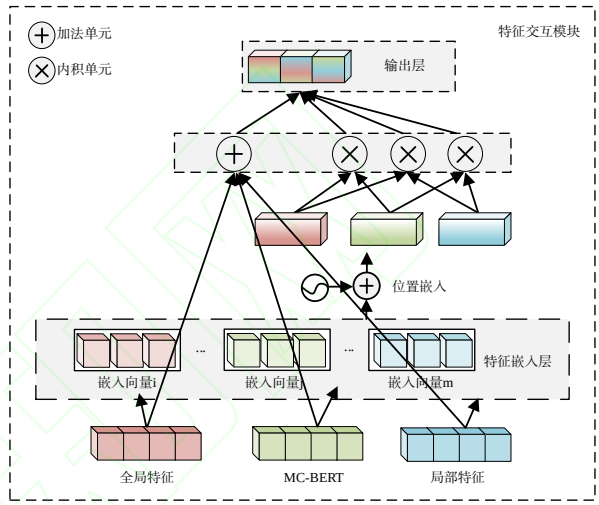


图 3 特征交互模块

Fig.3 Feature Interaction Module

该研究构建特征交互模块(RPEFM)，其结构如图 3 所示。其目的是通过强化多层次特征交互，来提升命名实体识别性能。该模块将 BiLSTM 提取的全局特征 $\boldsymbol{H}$、CharCNN 提取的局部特征 $\boldsymbol{C}$ 以及 MC-BERT 生成的上下文表示 $\boldsymbol{E}$ 转化为嵌入向量。在此基础上，引入位置嵌入以感知字符间相对位置信息，并利用加法单元与内积单元组成的交互层进行特征融合，从而有效捕捉三类特征间的一阶与二阶交互关系，聚合语义、结构与边界信息。第 i 个词的一阶交互项$\boldsymbol{f_i^{(1)}}$与二阶项交互项$\boldsymbol{f_i^{(2)}}$的计算公式如(7)与(8)所示：

$$\boldsymbol{f_i^{(1)}}=\boldsymbol{w_0}+\sum_{k=1}^{d_h}\boldsymbol{w_k^h}h_{i,k}+\sum_{m=1}^{dc}\boldsymbol{w_m^c}c_{i,m}+\sum_{p=1}^{d_e}\boldsymbol{w_p^e}e_{i,p} \tag{7}$$

$$\begin{aligned}\boldsymbol{f_i^{(2)}}=&\sum_{j=1}^{n}\sum_{k=1}^{d_h}\sum_{m=1}^{d_c}(\boldsymbol{v_k^h}\odot\boldsymbol{u_m^c}\odot\boldsymbol{r_{i\text{-}j}})h_{i,k}c_{j,m}\\&+\sum_{j=1}^{n}\sum_{k=1}^{d_h}\sum_{p=1}^{d_e}(\boldsymbol{v_k^h}\odot\boldsymbol{o_p^e}\odot\boldsymbol{r_{i\text{-}j}})h_{i,k}e_{j,p}\\&+\sum_{j=1}^{n}\sum_{m=1}^{d_c}\sum_{p=1}^{d_e}(\boldsymbol{u_m^c}\odot\boldsymbol{o_p^e}\odot\boldsymbol{r_{i\text{-}j}})c_{i,m}e_{j,p}\end{aligned} \tag{8}$$

其中，i 与 j 分别为序列中当前词与上下文词的位置索引，k、m 和 p 分别为全部特征 $\boldsymbol{H}$、局部特征 $\boldsymbol{C}$ 和上下文特征 $\boldsymbol{E}$ 的维度索引。$h_{i,k}$、$c_{j,m}$和$e_{j,p}$表示对应位置与维度上的特征分量。$\boldsymbol{w_o}$为可学习的全局偏置项，$\boldsymbol{w_k^h}$、

$\boldsymbol{w_m^c}$和$\boldsymbol{w_p^e}$分别为各特征的可学习权重。$\boldsymbol{v_k^h}$、$\boldsymbol{u_m^c}$和$\boldsymbol{o_p^e}$为其对应的二阶交互隐向量。$\boldsymbol{r_{i-j}}$为相对位置嵌入向量，⊙表示逐元乘法。第 i 个词的最终输出向量由一阶和二阶交互结果相加得到$\boldsymbol{f_i} = \boldsymbol{f_i^{(1)}} + \boldsymbol{f_i^{(2)}}$。

2.4 卷积层

本研究采用卷积神经网络作为网格表示细化模块，充分利用其在稀疏连接、参数共享与特征提取方面的优势。该模块包含三个子组件：条件归一化层用于构建词对网格表示，BERT 风格语义层用于增强词对语义信息，双轨卷积模块用于捕获近距离词间交互关系，以提升整体特征表达能力。

2.4.1 条件归一化层

在处理嵌套实体和不连续等复杂实体时，词对关系通常具有方向依赖特性，传统层归一化方法难以有效捕捉此类条件信息。因此，本研究引入条件归一化(Conditional Layer Normalization, CLN)机制，通过引入条件特征动态调整归一化参数，以构建更具表达能力的词对表示。在模型中，CLN 用于生成词对网格表示 $\boldsymbol{G} \in \mathbb{R}^{N\times N\times d_h}$，其中 $\boldsymbol{G_{ij}}$ 表示以 x_i 为条件时词对(x_i,x_j)的上下文依赖特征。该过程依赖于 RPEFM 层输出的字符表示 $\boldsymbol{F}=\{\boldsymbol{f_1},\boldsymbol{f_2},\ldots,\boldsymbol{f_n}\}$，其中$\boldsymbol{f_i} \in \mathbb{R}^{d_h}$。词对表示 $\boldsymbol{G_{ij}}$ 的具体计算公式如(9)-(11)所示：

$$\boldsymbol{G_{ij}} = CLN(\boldsymbol{f_i}, \boldsymbol{f_j}) = \boldsymbol{\alpha_{ij}} \cdot \left(\frac{\boldsymbol{f_j} - \mu_j}{\sigma_j}\right) + \boldsymbol{\beta_{ij}} \tag{9}$$

$$\mu_j = \frac{1}{d_h}\sum_{k=1}^{d_h} f_{jk} \tag{10}$$

$$\sigma_j = \sqrt{\frac{1}{d_h}\sum_{k=1}^{d_h}(f_{jk} - \mu_j)^2} \tag{11}$$

其中，$\boldsymbol{f_i}$ 为条件向量，用于动态生成增益参数$\boldsymbol{\alpha_{ij}} = \boldsymbol{W_r f_i} + \boldsymbol{b_r}$和偏置参数$\boldsymbol{\beta_{ij}} = \boldsymbol{W_\lambda f_i} + \boldsymbol{b_\lambda}$，$\mu_j$和$\sigma_j$分别表示向量 $\boldsymbol{f_j}$ 的均值和标准差，f_{jk} 表示 $\boldsymbol{f_j}$ 在第 k 个维度上的特征值。$\boldsymbol{W_r}$、$\boldsymbol{b_r}$、$\boldsymbol{W_\lambda}$和$\boldsymbol{b_\lambda}$为可学习参数，d_h 表示特征向量的维度。

2.4.2 词对 BERT 式网格表示

本研究通过融合词嵌入、位置嵌入与区域嵌入构建词对网格表示，以增强模型的语义建模能力。其中，词嵌入 $\boldsymbol{W} \in \mathbb{R}^{N\times N\times d_h}$由条件归一化层生成用于表征词对$(x_i, x_j)$的语义关联；位置嵌入 $\boldsymbol{P} \in \mathbb{R}^{N\times N\times d_p}$基于相对位置编码，以建模词对间距离与方向关系；区域嵌入 $\boldsymbol{R} \in \mathbb{R}^{N\times N\times d_r}$基于区域编码，用于区分对称结构并提升局部上下文感知能力。

将三类嵌入向量沿特征维度拼接，随后输入多层感知机（MLP），以实现特征融合与维度压缩。MLP 由三层线性变换组成，每层后接 *Batch Normalization* 和 *GELU* 激活函数，以增强特征的非线性表达能力。最终，模型输出兼具位置与区域感知能力的词对网格表示，计算公式如(12)所示：

$$\boldsymbol{E}_w = MLP_1([\boldsymbol{W};\boldsymbol{P};\boldsymbol{R}]) \tag{12}$$

其中，$[\boldsymbol{W};\boldsymbol{P};\boldsymbol{R}]$表示三类嵌入的拼接表示，$\mathrm{MLP}_1$ 通过层间变换将高维融合特征映射至目标维度 d_c，从而得到最终的网格表示 $\boldsymbol{E} \in \mathbb{R}^{N\times N\times d_c}$。

2.4.3 双轨卷积模块

为建模词对间的多层次交互关系，该研究提出双轨卷积结构，通过并行融合膨胀卷积(Dilated Convolution, DC)与标准卷积(Standard Convolution, SC)，既能捕捉不同尺度的词对依赖特征，又能通过特征融合增强表示能力。

双轨卷积模块包含两个分支组成，其结构如图 4 所示。上分支为膨胀卷积路径，设有两个不同膨胀率的卷积层，通过 *GELU* 激活函数与通道调整提升特征表达能力。下分支为标准卷积路径，由常规卷积、批量归一化和 *ReLU* 激活函数构成。最终，将两个分支的输出拼接后进行统一归一化处理，以确保特征的稳定性与一致性。

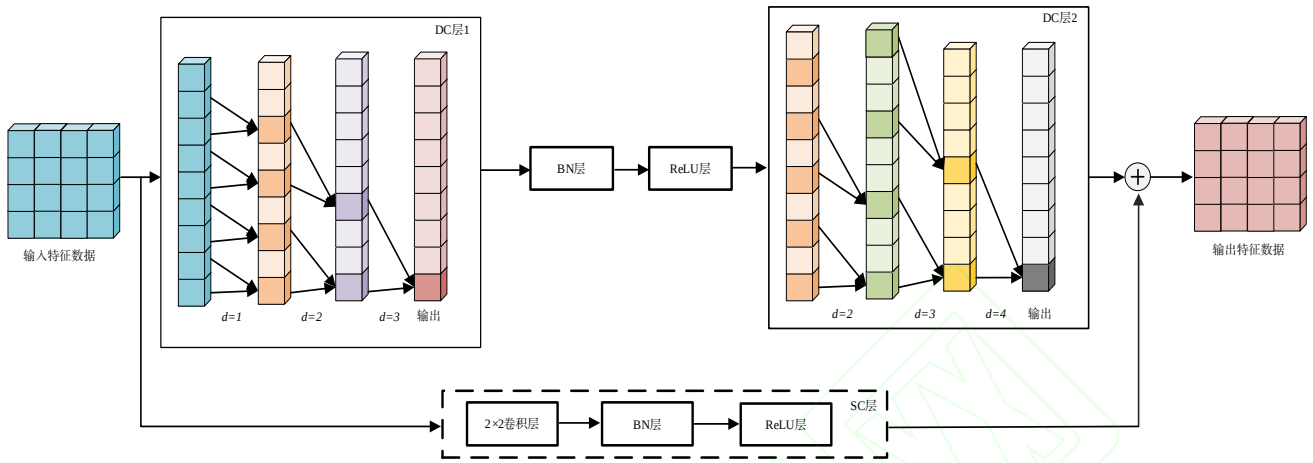


图 4 双轨卷积结构图

Fig.4 Dual-track Convolution Structure Diagram

1)标准卷积模块

标准卷积广泛应用于自然语言处理任务，能够通过固定尺寸的卷积核提取局部上下文信息。与引入扩张率的膨胀卷积相比，标准卷积在建模相邻词对的局部依赖关系方面具有更强的表达能力。采用卷积核大小 w=2，其计算公式如(13)所示：

$$\boldsymbol{S}_i = \sum_{k=-l}^{l} f_k \cdot \boldsymbol{E}_{i+k} + \boldsymbol{b} \tag{13}$$

其中，$f_k \in \mathbb{R}^{2\times 2\times d}$为位置 k 处的卷积核权重，l 表示卷积操作在序列方向上的覆盖范围，$\boldsymbol{b}$ 为偏置项，E_{i+k} 为输入特征在位置 $i+k$ 处的输入特征表示。为加快训练并缓解过拟合，卷积输出后经批量归一化和 *ReLU* 激活函数处理，表示为 $\boldsymbol{S}$=*ReLU(BN(*$\boldsymbol{S}$*))*。

2)膨胀卷积

为增强远距离依赖的建模能力，该研究设计双层膨胀卷积结构。第一层采用扩张率 $L\in[1,2,3]$，第二层在第一层的基础上扩张率增大为 L+1，以拓宽感受野并捕获更丰富的全局上下文信息。第一层膨胀卷积计算公式如(14)所示：

$$\boldsymbol{Q}_L^{(1)} = \sigma(DConv_L^{(1)}(\boldsymbol{E})) \tag{14}$$

其中，σ为 *GELU* 激活函数。$DConv_L^{(1)}$为第一次膨胀卷积操作，$\boldsymbol{E}$ 为输入特征，不同扩张率卷积结果拼接形成多粒度特征表示$\boldsymbol{Q}^{(1)} = [\boldsymbol{Q}_1^{(1)}, \boldsymbol{Q}_2^{(1)}, \boldsymbol{Q}_3^{(1)} \in R^{N\times N\times 3d}]$。

第二层膨胀卷积进一步增大扩张率为 L+1，以更充分地提取更高阶依赖特征表示 $\boldsymbol{Q}_L^{(2)} = \sigma(DConv_{l+1}^2(\boldsymbol{Q}_L^{(1)}))$，拼接后得到第二阶段多粒度特征表示$\boldsymbol{Q}_L^{(2)} = [\boldsymbol{Q}_2^{(2)}, \boldsymbol{Q}_3^{(2)}, \boldsymbol{Q}_4^{(2)} \in R^{N\times N\times 3d}]$。最终，将两种卷积模块的输出沿特征维度进行拼接，得到融合后的特征表示 $\boldsymbol{V}$=[**Q**,**S**]$\in \mathbb{R}^{N\times N\times 4d}$。

2.4.4 联合推理分类器

本研究在卷积层后设计联合推理分类器，用于识别词对(x_i, x_j)间的关系。该模块以词对网格表示 $\boldsymbol{V}$ 为输入，通过 RPN 和 MLP 协同预测，RPN 引入旋转位置编码(Rotary Position Embedding, RoPE)以增强位置信息感知能力，MLP 提取局部上下文特征，两者独立输出关系分布，通过融合得到最终预测结果，从而提升实体边界判定与类型识别的准确性。

1)旋转指针预测器

为有效识别嵌套实体与非连续实体并建模其内部依赖关系，本研究采用图 5 所示的旋转指针网络结构。通过两个独立的 MLP 生成词对的主语、宾语向量，再借助 RoPE 注入位置信息，最后经交互、缩放、线性变换操作，实现增强嵌套和非连续实体识别、优化实体依赖建模的目标。RPN 以 RPEFM 模块输出的上下文表示 $\boldsymbol{F}$=$\{\boldsymbol{f}_1,\boldsymbol{f}_2,\ldots,\boldsymbol{f}_n\}$为输入，计算公式如(15)和(16)所示：

$$\boldsymbol{s}_i = MLP_2(\boldsymbol{f}_i) \tag{15}$$

$$\boldsymbol{o}_j = MLP_3(\boldsymbol{f}_j) \tag{16}$$

其中，$\boldsymbol{s}_i$ 和 $\boldsymbol{o}_j$ 分别表示主语词 x_i 和宾语词 x_j 的表示。

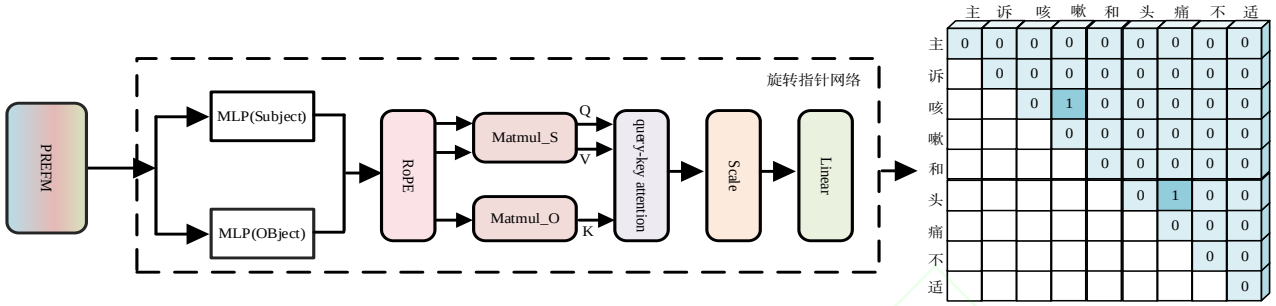


图 5 旋转指针网络结构图

Fig.5 Rotating Pointer Network Structure Diagram

为进一步增强位置感知与边界信息，本研究采用 RoPE 编码通过旋转矩阵运算将相对位置信息融入特征空间，从而实现精确的相对位置建模，计算公式如(17)所示：

$$\boldsymbol{R_i} = \begin{bmatrix} cos(i\theta) & -sin(i\theta) \\ \sin(i\theta) & cos(i\theta) \end{bmatrix} \tag{17}$$

其中，$\boldsymbol{R_i}$ 表示位置 i 对应的旋转矩阵，θ是频率参数，i 是位置索引。主语表示$\boldsymbol{s_i}$和宾语表示$\boldsymbol{o_j}$通过旋转矩阵进行旋转变换，计算公式如(18)和(19)所示：

$$\boldsymbol{s_i^{rot}} = \boldsymbol{R_i s_i} \tag{18}$$

$$\boldsymbol{o_j^{rot}} = \boldsymbol{R_j o_j} \tag{19}$$

其中，$\boldsymbol{s_i^{rot}}$和$\boldsymbol{o_j^{rot}}$分别为旋转变换后主语、宾语的增强表示。RPN 分类器利用旋转编码对实体对(x_i,x_j)的关系分数计算公式如(20)所示：

$$\boldsymbol{y_{ij}^{RPN}} = score(i,j) = (\boldsymbol{s_i^{rot}})^T \boldsymbol{o_j^{rot}} \tag{20}$$

其中，$\boldsymbol{y_{ij}^{PRN}} \in \mathbb{R}^{|\mathcal{R}|}$是$\mathcal{R}$中预定义关系分数组成的向量。

2)多层感知机预测器

基于卷积模块输出的词对网格表示 $\boldsymbol{V_{ij}}$,通过 MLP 计算词对(x_i, x_j)的关系分数，计算公式如(21)所示：

$$\boldsymbol{y_{ij}^{MLP}} = MLP(\boldsymbol{V_{ij}}) \tag{21}$$

其中，$\boldsymbol{V_{ij}}$ 为词对(x_i, x_j)的网格表示，MLP 用于将该表示映射为关系分数。为增强关系分类能力，本研究联合 MLP 和 RPN 进行推理。将两者输出的关系分数相加后经 *Softmax* 归一化,得到最终的关系概率分布 $\boldsymbol{y_{ij}}$，计算公式如(22)所示：

$$\boldsymbol{y_{ij}} = Softmax(\boldsymbol{y_{ij}^{RPN}} + \boldsymbol{y_{ij}^{MLP}}) \tag{22}$$

2.5 优化目标设计

本研究将预测结果建模为有向词图，边表示词对关系，实体通过图中路径解码生成，该路径同时编码边界与类别信息，兼顾实体边界识别与类别判定。为应对中文医疗文本中平面、嵌套、不连续实体及路径歧义等复杂结构，不同命名实体识别示例分析如图 6 所示。解码层联合引入 RPN 和 MLP。RPN 动态调整指针方向，建模复杂实体间结构依赖，处理嵌套与不连续实体。MLP 优化词对表示，提升边界与类别判别能力。同时，模型引入语法与语义依赖等辅助信息，增强词间组合的合法性与语义一致性,缓解实体歧义，提升复杂实体识别能力。

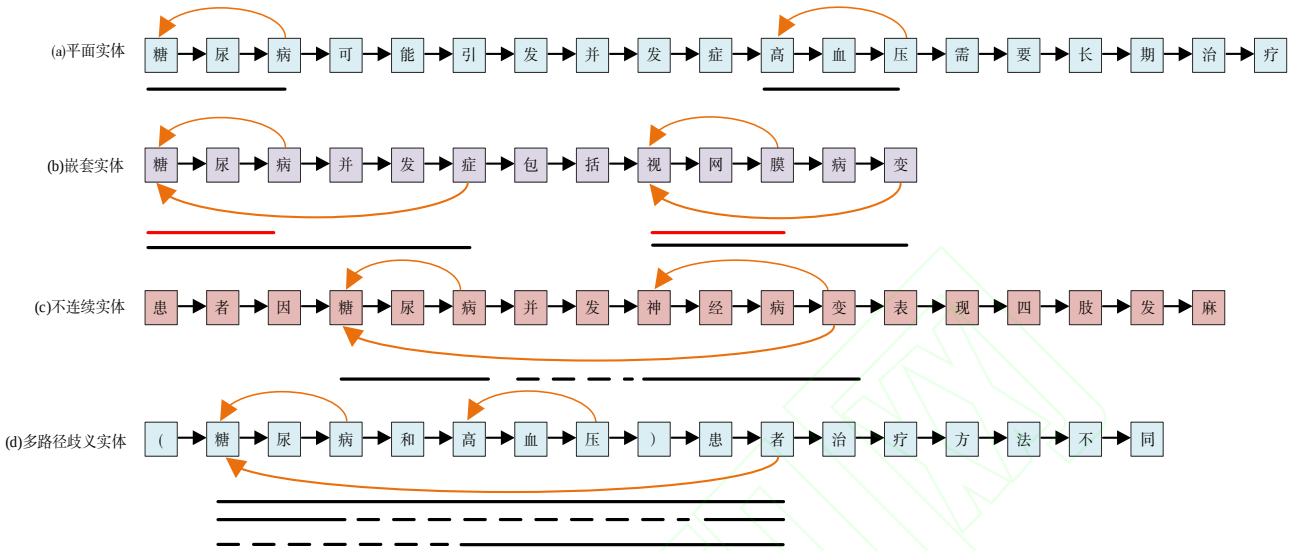


图 6　不同命名实体识别示例分析(黑色箭头直线表示为头尾词与词之间关系(N)，橘黄色箭头曲线表示尾头词与词之间辅助关系(T))

Fig.6　Analysis of different named entity recognition examples (black straight arrows indicate the relationship between head and tail words (N), and orange curved arrows indicate the auxiliary relationship between tail and head words (T))

示例(6-a)：“糖尿病”和“高血压”为两个平面实体，借助 T 关系可直接区分。

示例(6-b)：缺乏 T 关系时，模型可能将“糖尿病并发症”识别为整体，忽略“并发症”等内部实体。引入 T 关系后，模型能够准确识别“并发症”嵌套在其中。

示例(6-c)：N 关系可连接不连续实体。如，“糖尿病→并发→神经病变”路径帮助识别“糖尿病”和“视网膜病变”为一个实体。

示例(6-d)：单独使用 N 关系可能引发歧义。例如将“糖尿病和高血压患者”被误识为一个实体。结合 T 关系可正确识别“糖尿病”和“高血压”为独立实体。

在训练过程中，模型以最小化与真实标签相关的负对数似然损失为目标。具体损失函数定义，计算公式如(23)所示：

$$\mathcal{L}=-\frac{1}{N^2}\sum_{i=1}^{N}\sum_{j=1}^{N}\sum_{r=1}^{|R|}\hat{y}_{ij}^{r}\log y_{ij}^{r} \tag{23}$$

其中，N 为句子长度，$\hat{y}_{ij}^{r}$是一个二进制向量，用于表示词对(x_i, x_j)对应关系集合 R 中第 r 种关系的真实标签，$\boldsymbol{y}_{ij}^{r}$是模型针对词对(x_i, x_j)属于关系 r 的预测概率向量，$|R|$为预定义关系集合 R 的大小，r 表示预定义关系集合 R 中的第 r 种关系。

为清晰呈现模型内部特征变换过程，表 1 系统展示了各模块的输入输出维度。维度变化体现从字符序列到词级表示、特征交互、词对网格构建，最终输出实体关系预测的完整计算路径。

表 1　各模块输入输出维度表

Table 1　Input and Output Dimensions Table for Each Module

模块	输入维度	输出维度
MC-BERT	$b\times l$	$b\times l\times d_{bert}$
BiLSTM	$b\times l\times d_{bert}$	$b\times l\times d_{lstm}$
CharCNN	$b\times l\times d_{bert}$	$b\times l\times d_{char}$
RPEFM	$b\times l\times d$	$b\times l\times d$
CLN	$b\times l\times d$	$b\times l\times l\times d_c$
双轨卷积	$b\times l\times l\times d_c$	$b\times l\times l\times d_{conv}$
MLP 分类器	$b\times l\times l\times d_{conv}$	$b\times l\times l\times c$
RPN 分类器	$b\times l\times d_f$	$b\times l\times l\times c$

其中，b 为训练批次大小，值为 10；l 为文本序列长度；d_{bert} 为隐藏层大小，值为 768；d 为隐藏层维度，值为 512；d_c 为词对网格维度，值为 552；d_{conv} 表示卷积维度，值为 240；d_f 为线性变换后的隐藏层维度，值为 120；c 为实体类别数目。

3.　实验验证

3.1　数据集

该研究在三个中文医疗命名实体识别数据集 CMeEE-V2、IMCS-V2 和 CMeIE-V2 及通用领域中文社交媒体数据集 Weibo 上进行实验，前者用于模型性能评估，后者验证泛化能力。实验结果表明，所提出的 MLFM 模型在各数据集上均表现出最优性能，数据集详情见表 2。

表 2 数据集描述

Table 2 Description of The Datasets

数据集	训练集/验证集/测试集	实体种类
CMeEE-V2	15000/5000/3000	疾病、临床表现、医学检验项目、医疗设备、医疗程序、身体、微生物类、科室、身体、药物
IMCS-V2	2472/833/411	症状、药品名称、药物类别、检查、操作
CMeIE-V2	14339/3585/1391	其他、手术治疗、检查、流行病学、疾病、其他治疗、症状、社会学、药物、部位、预后
Weibo	1350/270/270	人名、地名、组织、地缘政治实体

1、CMeEE-V2：嵌套医疗数据集，来源于医疗教材、临床病历及期刊，涵盖大量医疗术语。

2、IMCS-V2：面向智能诊疗的对话式数据集，取自真实医患对话文本。

3、CMeIE-V2：医疗信息抽取数据集，聚焦儿科及常见疾病领域，包含丰富医疗知识。

4、Weibo：中文通用领域社交媒体数据集，用于验证模型的领域泛化能力。

3.2 实验基准

为验证所提方法的有效性，选取 10 个具有代表性的中文命名实体识别模型作为对比基线，涵盖经典序列标注方法与最新结构建模机制，具体如下：

(1)BERT-CRF[5]：该方法通过 BERT 提取上下文表示，结合 CRF 建模标签依赖关系，提升标注精度。

(2)BERT-BiLSTM-CRF：在 BERT 基础上引入 BiLSTM 捕捉序列特征，配合 CRF 提升实体识别性能。

(3)BERT-IDCNN-CRF：采用 BERT 提取语义表示，IDCNN 捕获局部上下文特征，并以 CRF 建模标签依赖关系，通过多模块协同提升整体性能。

(4)Lattice-LSTM[4]：由 Lattice-LSTM 和 CRF 两层组成，前者融合字词信息建模上下文信息特征，后者捕捉标签依赖，提升序列标注准确性。

(5)LR-CNN[23]：结合词典匹配与 CNN 结构，引入反馈机制缓解词冲突，提升中文实体识别效果。

(6)WC-LSTM[24]：将字符与外界词汇嵌入融合，结合 LSTM 提取特征，增强实体边界建模能力。

(7)GP[17]：通过全局指针机制直接预测实体跨度，并引入相对位置编码建模边界信息，具备较高效率与准确性。

(8)W2NER[25]：基于二维卷积建模词对关系，结合协同预测机制识别实体边界与类型。

(9)TOE[26]：建模词-词、词-标签与标签-标签间关系，引入更细粒度标签体系，提升识别精度。

(10)MSE[22]：基于自蒸馏的多层语义增强框架，通过数据增强缓解数据不平衡与重加权策略显著提升中文 NER 性能。

3.3 实验设置与评估标准

本实验系统为 Ubuntu 20.04，开发环境为 Python 3.8，Cuda 版本为 11.8，GPU 为 RTX4090(24GB)，Pytorch 版本为 2.0.0，Transformers 版本为 4.13.0。

3.3.1 超参数设置

为使 MLFM 模型在中文医疗命名实体识别任务中实现最佳性能，同时在数据变化场景下保持公平性，所有实验采用统一参数设置：训练轮数 20、批大小 10，取最优指标作为结果。模型以预训练 MC-BERT 作为嵌入层，距离嵌入与类型嵌入维度均为 20，其余参数详见表 3。

表 3 超参数设置

Table 3 Hyperparameter Settings

超参数	参数值
LSTM 隐藏层	512
卷积隐藏层	80
膨胀系数	[1,2,3]
滤波器数量	5
卷积核尺寸	[2,4,5,6,8]
CharCNN 隐藏维度	384
前馈神经网络隐藏层	120
RPEFM 隐向量维度	10
优化器	AdamW
学习率	5e-6

3.3.2 评估指标

采用精确率(Precision)、召回率(Recall)和 F1 分数(F1-score)这三项指标作为主要评价指标，三者能全面且综合的评估 MLFM 模型的整体识别性能。计算公式如(24-26)所示：

$$Precision = \frac{TP}{TP + FP} \tag{24}$$

$$Recall = \frac{TP}{TP + FN} \tag{25}$$

$$F1-score = 2 * \frac{Precision * Recall}{Precision + Recall} \tag{26}$$

其中，TP 表示正类样本被正确识别为正类，FP 表示负类样本被误识为正类，FN 表示正类样本被误识为负类。

3.4 实验结果分析

为全面评估模型性能，本研究在 CMeEE-V2、IMCS-V2、CMeIE-V2 及 Weibo 数据集上进行了对比实验。结果验证了 MLFM 模型相较于现有基线方法的优越性。

表 4 CMeEE-V2、IMCS-V2 和 CMeIE-V2 数据集实验结果

Table 4 The Experimental Results of CMeEE-V2、IMCS-V2 and CMeIE-V2 Datasets

Model	CMeEE-V2			IMCS-V2			CMeIE-v2		
	F1	Precision	Recall	F1	Precision	Recall	F1	Precision	Recall
BERT-CRF	61.37%	55.77%	68.21%	83.48%	77.27%	90.78%	70.17%	63.04%	69.11%
BERT-IDCNN-CRF	63.76%	62.82%	64.73%	81.72%	79.72%	83.82%	70.74%	68.26%	73.40%
BERT-BiLSTM-CRF	63.15%	57.14%	70.58%	83.16%	77.82%	89.29%	71.68%	69.79%	73.68%
Lattice-LSTM	66.23%	66.78%	65.69%	85.89%	86.71%	85.08%	67.97%	67.09%	68.86%
LR-CNN	71.35%	71.38%	71.32%	70.59%	69.88%	71.31%	70.64%	70.56%	70.73%
WC-LSTM	66.77%	67.70%	65.86%	86.59%	87.05%	86.13%	66.72%	67.22%	66.23%
GP	65.78%	68.39%	63.37%	90.57%	90.70%	90.12%	71.21%	78.97%	64.84%
W2NER	74.99%	74.68%	75.13%	90.65%	90.05%	90.51%	75.09%	75.22%	74.96%
TOE	75.52%	**76.08%**	75.63%	89.84%	89.34%	90.34%	75.28%	**79.75%**	75.34%
MSE	69.82%	68.81%	70.86%	87.90%	87.49%	88.30%	73.20%	72.16%	73.20%
MLFM(ours)	**75.90%**	75.93%	**76.18%**	**91.22%**	**91.46%**	**90.97%**	**76.14%**	75.10%	**77.81%**

3.4.1 医疗领域数据集中模型性能对比

表 4 显示了 MLFM 模型与多个主流实体识别模型在三个中文医疗数据集上的对比结果。从表 4 可以看出，MLFM 模型在所有数据集上均取得较高 F1 值，体现了其在复杂实体识别中的稳定性、鲁棒性与泛化能力。在 CMeEE-V2 数据集中，较基础序列标注模型 BERT-CRF、BERT-BiLSTM-CRF、BERT-IDCNN-CRF 分别提升 14.58%、12.8%、12.19%。在引入外部词汇信息的模型中，MLFM 模型相比 LR-CNN、Lattice-LSTM、WC-LSTM 分别提升 4.6%、9.72%、9.18%。对比先进模型，MLFM 较 W2NER、TOE、MSE 分别提升 0.96%、0.43%、6.13%。

相比基础序列标注模型，MLFM 模型通过引入 BiLSTM 和 CharCNN 增强全局与局部特征捕捉能力，以旋转指针网络替代传统 CRF，从而有效解决了实体嵌套和长距离依赖问题，实现性能提升。与依赖外部词汇信息的模型相比，其性能受外部词汇质量影响较大，而 MLFM 摒弃词典依赖，通过多层次特征融合与动态交互机制，有效减轻分词错误影响，提升泛化能力与鲁棒性。相比先进模型，W2NER 和 TOE 模型虽在性能上表现优异，但文本语义捕获能力不及 MLFM 模型，MSE 模型虽采用数据增强，但缺乏噪声过滤，在医疗领域适应性较弱。总体而言，MLFM 通过加强局部与全局信息融合及灵活边界建模，实现更精准的实体识别，尤其在复杂实体结构处理中优势显著。

在 IMCS-V2 数据集中，MLFM 模型在各类对比模型中优势显著。与基础序列标注模型相比，MLFM 较 BERT-CRF、BERT-BiLSTM-CRF 和 BERT-IDCNN-CRF 分别提升 7.74%、8.06%和 9.5%，体现其在序列特征与上下文语义捕捉上的更强能力。在依赖外部词汇的模型中，MLFM 相较于 LR-CNN、Lattice-LSTM、WC-LSTM 分别取得了 20.63%、5.33%、4.63%的性能提升，表明了 MLFM 模型端到端建模能有效规避词典覆盖率不足与分词误差，从而提升了模型的泛化性能。

与当前较为先进模型相比，MLFM 较 W2NER、TOENER、MSE、GP 分别提升 0.57%、1.38%、3.32%、

0.65%。这得益于其多层次特征融合与动态交互机制，该机制在轻量计算开销下，有效增强了模型对实体边界、上下文依赖及复杂结构的建模能力，从而展现出更强的鲁棒性与泛化性能。

3.4.2 通用领域数据集中模型性能对比

为验证 MLFM 模型在其他领域的泛化能力，本研究在通用领域 Weibo 数据集上进行了对比实验，所用预训练模型和 MSE 模型一致，实验结果如图 7 所示。

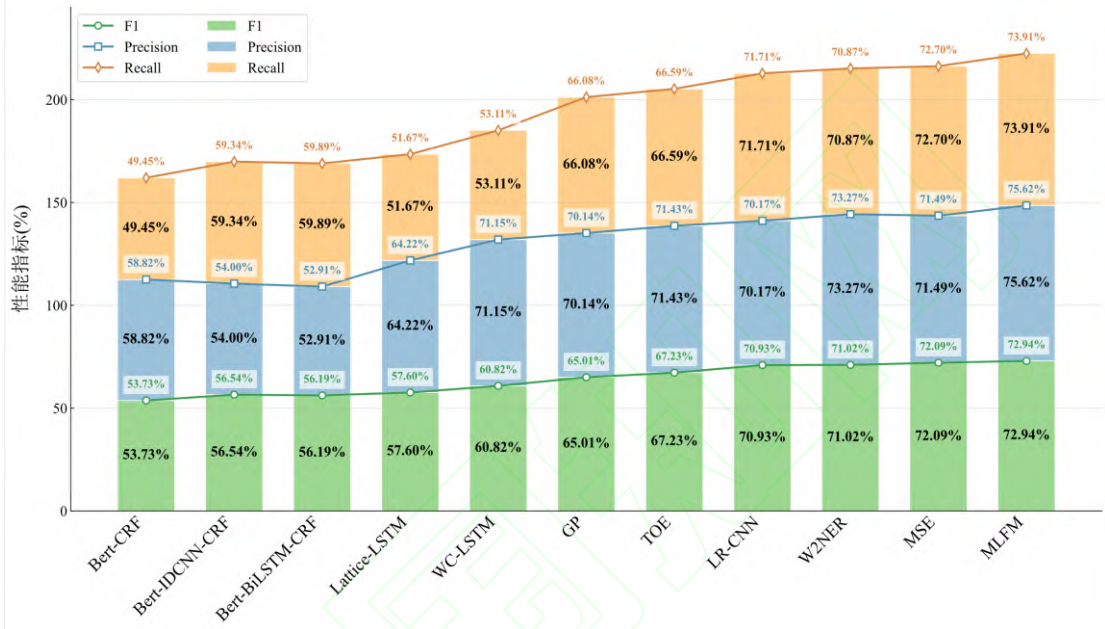


图 7 Weibo 数据集各模型性能对比图

Fig.7 Comparison of Performance of Various Models on the Weibo Dataset

实验结果表明，在通用数据集 Weibo 上，MLFM 模型表现突出，在所有对比模型中取得最优 F1 值。作为典型社交媒体文本，Weibo 数据集具有语言非规范化、实体边界模糊、嵌套与不连续实体结构普遍等特点，对实体识别提出更高挑战。MLFM 融合 BERT 的语义建模、BiLSTM 的上下文理解及 CharCNN 的局部特征提取优势，引入 RPEFM 模块实现全局与局部信息的动态融合，使模型在复杂文本环境中表现出更强的鲁棒性和泛化能力。

从性能提升角度看，MLFM 模型在 Weibo 数据集上较 W2NER 模型提升 1.92%，较 LR-CNN 模型提升 2.01%，较 GP 模型提升 7.93%，较 Lattice-LSTM 模型提升 15.68%，相较 BERT 系列模型提升超过 16%。TOE 模型虽通过多重关系建模增强标签表达能力，但在处理非结构化文本噪声与长距离依赖方面仍存在不足，MLFM 模型相较其提升 5.71%。MSE 模型借助自蒸馏和语义增强取得较好表现，但因缺乏噪声过滤机制，整体鲁棒性不及 MLFM 模型，F1 值低 0.85%。

3.5 消融实验

3.5.1 模块消融实验分析

通过设计消融实验分析各模块对 MLFM 模型性能的贡献，依次移除或替换特定模块，并在 CMeEE-V2、IMCS-V2 和 CMeIE-V2 三个医疗数据集上进行评估，结果如表 5 所示。

表 5 消融实验的 F1 值结果(%)

Table 5 Ablation Study Results on F1 Score(%)

	CMeEE-V2	IMCS-V2	CMeIE-v2

Ours	**75.95**	**91.22**	**76.14**
w/o CharCNN	75.13(-0.82)	90.29(-0.93)	75.53(-0.61)
w/o BiLSTM	75.27(-0.68)	90.31(-0.91)	75.47(-0.67)
w/o RPEFM	74.37(-1.58)	90.15(-1.07)	75.19(-0.95)
- DR	75.62(-0.33)	90.63(-0.59)	75.09(-1.05)
w/o RPN	75.03(-0.92)	90.56(-0.66)	75.30(-0.84)
w/o MLP	74.70(-1.25)	89.39(-1.83)	74.30(-1.84)

本研究移除局部特征模块(w/o CharCNN)和全局特征模块(w/o BiLSTM)后，F1 值平均下降约 0.70%，表明两者在捕捉细粒度和长距离依赖信息中均发挥关键作用。去除特征交互模块(w/o RPEFM)导致性能下降最高达 1.58%，验证了其在融合多源特征中的重要性。将双轨卷积替换为单一结构(- DR)使 F1 值下降了 0.33%~1.05%，表明双轨结构有助于多粒度特征建模。在联合推理器中，去除 RPN 与 MLP 均引起明显性能下降，尤其 MLP 影响更大，表明两者联合推理可显著提升实体边界与类型识别精度。

消融实验结果表明，MLFM 模型的四个核心模块均对性能提升具有重要作用。其中，特征交互 RPEFM 模块影响最为显著，双轨卷积和联合推理器则在多粒度特征建模与推理优化中发挥关键作用，验证了模型设计的合理性与有效性。

3.5.2 参数消融实验

设计了三组对比实验评估卷积滤波器数量与卷积核大小对模型性能的影响：a 组(3 个滤波器，核大小为[2,4,6])，b 组(5 个滤波器，核大小为[2,4,5,6,8])，c 组(8 个滤波器，核大小为[1,2,3,4,5,6,8,10])，其余参数保持不变。实验结果如图 8 所示。

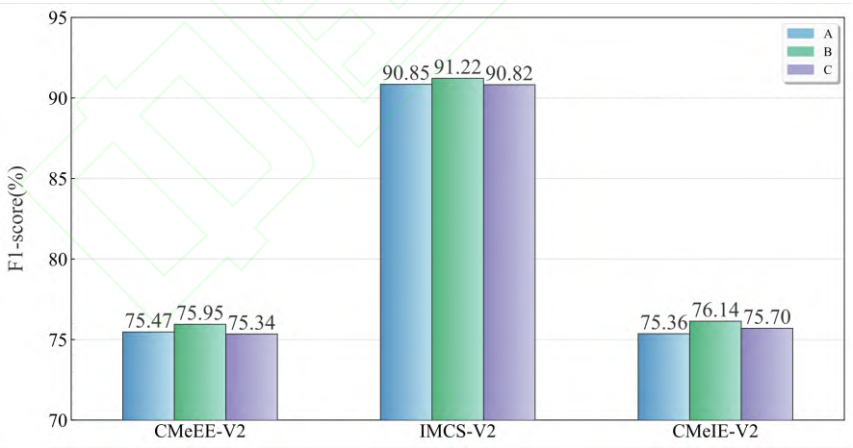


图 8 不同的滤波器和卷积核的大小的 F1 值

Fig.8 F1 Scores for Different Filter Sizes and Kernel Sizes

在三个医疗数据集上，采用 5 个滤波器(b 组)时 F1 值表现最佳且最高，略优于使用 3 个滤波器(a 组)的参数配置。然而，当滤波器数量进一步增加至 8 个(c 组)时，模型性能反而出现轻微下降趋势。实验结果表明，适度增加滤波器数量有利于提取多尺度特征表示，但过多滤波器会引入特征冗余，导致模型判别能力趋于饱和、难以获得进一步提升。因此，滤波器的数量应依据具体任务的复杂度予以权衡配置。

3.5.3 参数敏感性分析

本节对 RPEFM 隐向量维度和双轨卷积膨胀率两个关键超参数进行敏感性分析，以评估模型稳健性并探究其工作机制。隐向量维度大小决定特征表示与融合能力，膨胀率调控感受野范围以影响上下文信息捕获。通过控制变量实验，揭示了参数与性能的内在关联，为超参数设置提供了依据。

图 9 展示了 RPEFM 模块隐向量维度的敏感性分析结果。实验结果表明，模型性能随着维度增加呈现先升后降的趋势。在维度为 10 时达到最优性能。该趋

势表明，维度过低会导致模型的表征能力不足，过高则会引入特征冗余，从而造成模型性能下降并影响泛化能力。

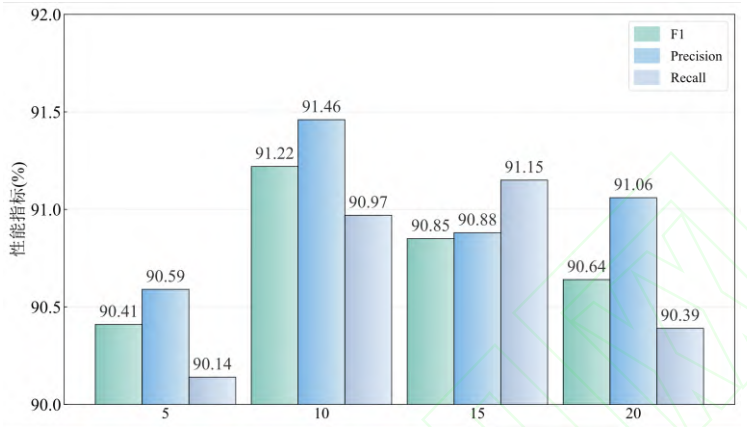


图 9 RPEFM 隐向量维度敏感性分析

Fig.9 Sensitivity Analysis of RPEFM Latent Vector Dimension

图 10 展示了双轨卷积模块中不同膨胀率组合对模型性能的影响。实验结果表明，模型性能随膨胀率增大呈先升后降趋势。组合[1,2,3]取得最优性能，其精确率、召回率和 F1 分数分别达 91.46%、90.97%和91.22%。分析表明，较小膨胀率组合[1,2,1]因感受野有限，难以获取充分上下文信息；过大膨胀率组合[2,4,6]则因卷积核稀疏而削弱局部特征表达能力。结果表明，组合[1,2,3]通过多尺度感受野的协同作用，在局部特征提取与全局依赖建模之间取得了最佳平衡，从而确保了模型的优异性能与稳定性。



图 10 双轨卷积膨胀率敏感性分析

Fig.10 Sensitivity Analysis of Dilation Rate in Dual-Path Convolution

3.5.4 基于不同数据集的实体标签关联分析

为深入探究不同数据集中实体标签的分布特性并有效量化标签间的相关性，本研究在 CMeEE-V2、IMCS-V2、CMeIE-V2 和 Weibo 四个数据集上，进行了实体标签相关性热力图的系统绘制与可视化分析，其结果如图 11 所示。

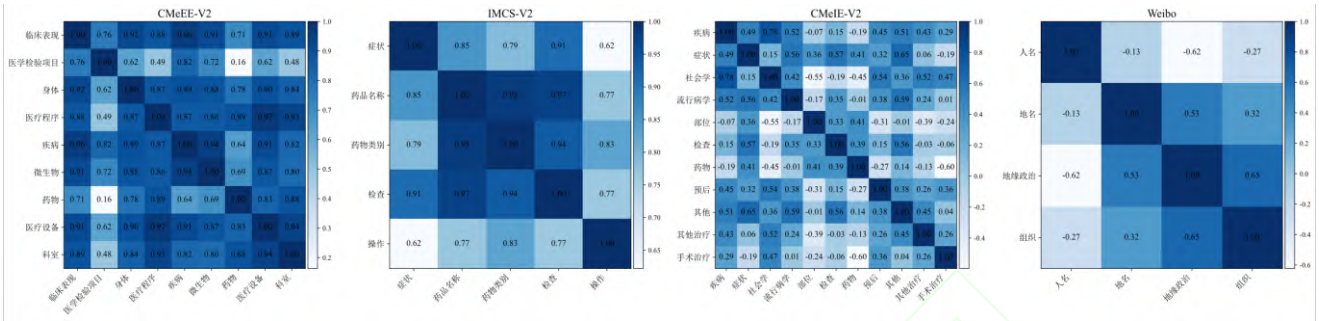


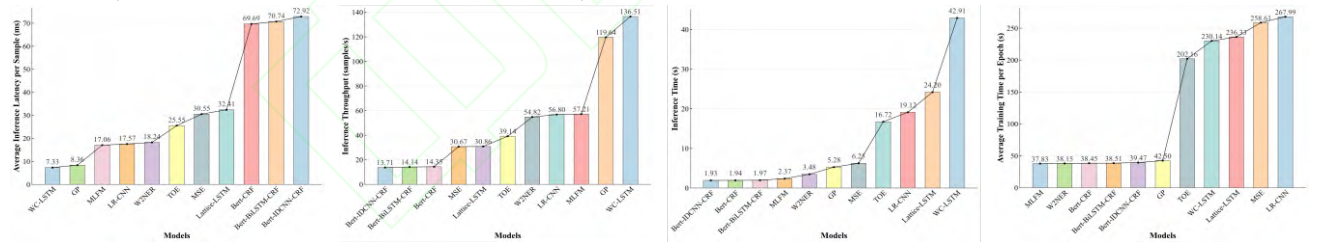
图 11　不同数据集标签间相关性分析

Fig.11　Correlation Analysis Between Labels of Different Datasets

实验结果表明，不同数据集的标签分布特征存在显著差异。在 CMeEE-V2 中，疾病与临床表现、医学检验项目等标签呈现较高相关性，说明医疗文本中症状、检查与疾病往往同时出现，存在明显的语义耦合。在 IMCS-V2 中，症状与检查、药品名称与药物类别的相关性均接近 0.9，符合在真实医患对话场景中，症状描述后常伴随检查建议、而具体药品也常与其所属类别一同被提及。而在 CMeIE-V2 中，不同标签之间的相关性差异较大，部分甚至为负相关，例如社会学与流行病学，表明该数据集更强调实体之间的结构化和层级关系，同时也凸显了疾病与部位的高度共现特征。相比之下，Weibo 数据集的标签相关性整体较弱，甚至出现人名与地缘政治实体为负相关的情况，这反映出社交媒体文本噪声大、语境非规范化，实体分布较为分散。总体而言，医疗类数据集中实体标签之间普遍存在较强共现关系，而通用领域则呈现出弱相关甚至负相关的模式，从统计层面揭示了不同数据集间的语义差异，为模型性能差异提供了内在解释，从而与性能指标形成交叉验证，增强了结论的稳健性。

3.5.5　模型性能在多维度指标上的对比实验

本研究基于 IMCS-V2 数据集，通过平均单样本推理延迟、推理吞吐量、测试时间及平均每轮训练时间四项核心效率指标，对模型性能进行多维度量化剖析，如图 12 所示。



(a)模型平均单样本推理延迟对比　(b)模型推理吞吐量对比　(c)模型测试时间对比　(d)模型平均每轮训练时间对比

图 12　模型不同维度推理速度对比图

Fig.12　Comparison Chart of Inference Speed of Models Across Different Dimensions

实验结果表明，MLFM 模型在多项效率指标上展现出良好的综合性能。从图 12(a)可见，在单样本推理延迟方面，MLFM 通过 RPN 与 MLP 联合推理机制有效规避了序列解码的串行瓶颈，其延迟为 17.06 毫秒，显著低于 BERT-BiLSTM-CRF 的 70.74 毫秒，虽高于极简结构 WC-LSTM 的 7.33 毫秒与 GP 的 8.36 毫秒，但得益于其强大的表达能力，MLFM 在性能与速度之间取得了更优的平衡。图 12(b)显示，在批量处理方面，MLFM 的吞吐量达到了 57.21 样本/秒，远超 BERT 系列基线，这主要得益于其双轨卷积结构形成的规整计算图，能够充分发挥 GPU 并行计算优势，显著提升了计算资源的利用效率。图 12(c)和图 12(d)进一步表明，在测试时间与训练效率方面，MLFM 均显著优于结构复杂的对比模型，同时其单轮训练时间为 37.83 秒，与多数基准模型保持相当水平。实验结果表明，MLFM 在模型性能与计算效率之间取得了有效平衡，其在不同负载条件下均保持稳定的性能表现，为需要兼顾识别精度与推理速度的实际应用场景提供了有价值的解决方案。

3.5.6　基于不同预训练模型的实验性能对比研究

医疗 NER 任务的效果在很大程度上取决于预训

练模型的语义表达能力。为系统评估不同模型的适配性能，本研究对九种预训练语言模型(包括 BERT、BERT-NER、BioBERT、ClinicalBERT、ERNIE-Health、XLNet、MACBERT、RoBERTa 和 MC-BERT)在三个不同的医疗领域数据集下进行了对比实验。所有模型均基于 Hugging Face 的预训练参数，在统一的实验设置下完成训练与测试，结果如图 13 所示。

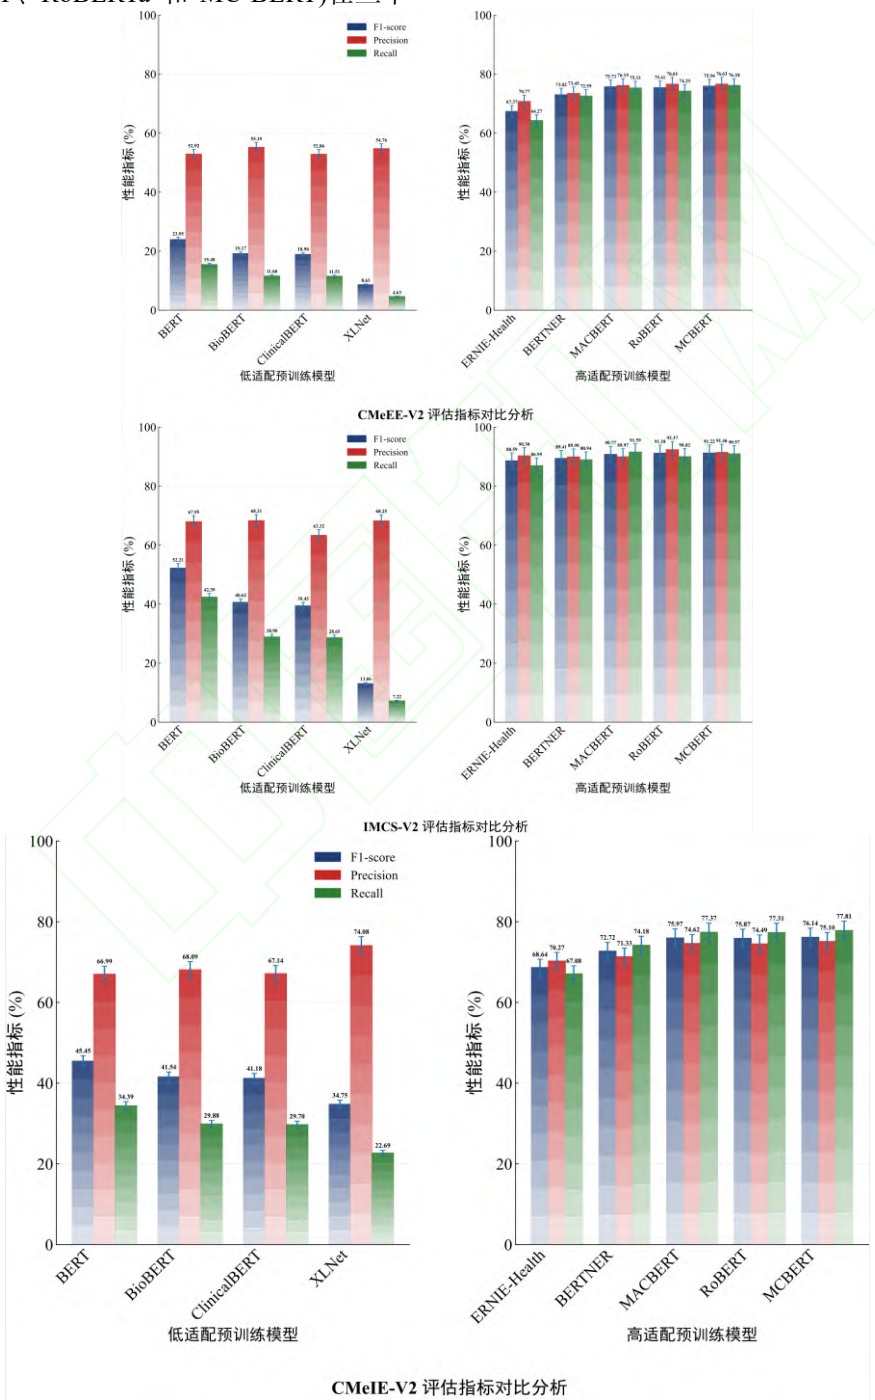


图 13 不同预训练性能对比

Fig.13 Comparison of the performance of different pre-trained

针对九种预训练模型在三个医疗数据集上的性能评估表明，BERT-NER、ERNIE-Health、MACBERT、RoBERTa 和 MC-BERT 表现突出。其中，BERT-NER 在中文命名实体识别任务上进行过持续训练，内部表征已内化该领域先验知识，因而能更准确地识别实体边界与类别。ERNIE-Health 基于大规模中文医疗语料

预训练，具备较强的语义理解。MACBERT 通过同义词替换优化掩码训练，有效捕获细粒度语义特征。RoBERTa 依托动态掩码技术与大规模中文数据，显著增强了上下文建模能力，尤其擅长捕获长距离依赖关系。MC-BERT 作为专门针对中文医疗领域预训练的模型，能够精准识别医疗术语和句法结构，该模型因其在 F1 值最高、且精确率、召回率与领域适配能力均表现优异，整体效果突出，因此将其作为首选模型。

相比之下，基础 BERT、BioBERT、ClinicalBERT 和 XLNet 表现相对较弱。基础 BERT 由于预训练语料较为通用，缺乏医疗专业知识，导致识别能力有限。BioBERT 和 ClinicalBERT 虽然针对生物医疗及临床领域预训练，但其训练语料主要为英文，且与中文医疗文本存在较大差异，导致在中文医疗任务上的适配性不足。XLNet 虽然采用自回归预训练方式，理论上建模能力强，但其通用语料与中文医疗语境契合度较低，表现不理想。

4. 结束语

针对传统 NER 模型在处理嵌套与不连续等复杂实体时存在的局限性，该研究提出多层次特征融合模型 MLFM。该模型融合 MC-BERT、BiLSTM 与 CharCNN 提取的多粒度语义特征，结合 RPEFM 实现动态特征交互与结构感知建模，利用双轨卷积优化词对表示，增强边界与类型判别能力，并通过 MLP 与 RPN 联合推理，提升复杂实体识别精度。实验验证了 MLFM 模型在中文医疗 NER 任务中的有效性与先进性。

在 CMeEE-V2、IMCS-V2、CMeIE-V2 和 Weibo 数据集上，MLFM 模型在识别嵌套和不连续等复杂实体方面显著优于现有方法。此外，消融实验验证了多层次融合与交互机制对性能提升的关键作用，展现出良好的跨领域泛化能力。

未来工作将聚焦于医疗实体识别中的类别不平衡与知识融合不足等核心挑战，采用数据增强与对比学习技术，针对性优化低频及复杂实体的表征质量与分布结构。同时，探索将医疗领域词典以动态融合方式注入预训练过程，以增强模型对专业术语与领域知识的语义捕捉能力。从而进一步提升模型在复杂医疗实体识别任务上的性能表现。

参考文献：

[1] 杜晋华,尹浩,冯嵩.中文电子病历命名实体识别的研究与进展[J].电子学报,2022,50(12):3030-3053.
DU J H, YIN H, FENG S. Research and Development of Named Entity Recognition in Chinese Electronic Medical Record[J]. Acta Electronica Sinica, 2022, 50(12): 3030-3053.

[2] ZHANG H, ZONG Y, CHANG B, et al. medical entity annotation standard for medical text processing[C]//Proceedings of the 19th Chinese national conference on computational linguistics. 2020: 561-571.

[3] KE J, WANG W, CHEN X, et al. Medical entity recognition and knowledge map relationship analysis of Chinese EMRs based on improved BiLSTM-CRF[J]. Computers and Electrical Engineering, 2023, 108: 73-91.

[4] ZHANG Y, YANG J. Chinese NER Using Lattice LSTM[C]//Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2018: 1554-1564.

[5] DEVLIN J, CHANG M W, LEE K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[C]// Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers). 2019: 4171-4186.

[6] HOU J, SAAD S, OMAR N. Enhancing traditional Chinese medical named entity recognition with Dyn-Att Net: a dynamic attention approach[J]. PeerJ. Computer science, 2024, 10: e2022.

[7] SONG B S, LI F, LIU Y S, et al. Deep learning methods for biomedical named entity recognition: a survey and qualitative comparison[J]. Briefings in Bioinformatics, 2021, 22(6): 1-18.

[8] COLLOBERT R, WESTON J, BOTTOU L, et al. Natural Language Processing (Almost) from Scratch[J]. Journal of Machine Learning Research, 2011, 12: 2493-2537.

[9] 曹依依,周应华,申发海,等.基于 CNN-CRF 的中文电子病历命名实体识别研究[J]. 重庆邮电大学学报(自然科学版), 2019, 31(6): 869-875.
CAO Y Y, ZHOU Y H, SHEN F H, et al. Research on named entity recognition of Chinese electronic medical record based on CNN-CRF[J]. Journal of Chongqing University of Posts and Telecommunications(Natural Science Edition), 2019,31(6): 869-875.

[10] TANG X, HUANG Y, XIA M, et al. A multi-task BERT-BiLSTM-AM-CRF strategy for Chinese named entity recognition[J]. Neural processing letters, 2023, 55(2): 1209-1229.

[11] LENG F, LI F, BAO Y, et al. DABC: A Named Entity Recognition Method Incorporating Attention Mechanisms[J]. Mathematics,

2024, 12(13): 71-86.
[12] 林令德,刘纳,徐贞顺,等.基于多层动态融合的中文医疗命名实体识别[J].计算机工程与应用, 2024, 60(15): 161-169.
LIN L D, LIU N, XU Z S, et al. Chinese Medical Named Entity Recognition Based on Multi-Layer Dynamic Fusion[J]. Computer Engineering and Applications. 2024, 60(15): 161-169.
[13] 周文卓,廖光忠.基于 RBIEGP 的中文医疗实体识别[J].计算机技术与发展,2025,35(6): 124-130.
ZHOU W Z, LIAO G Z. Chinese Medical Entity Recognition Based on RBIEGP[J]. Computer Technology and Development, 2025, 35(6): 124-130.
[14] ZHANG B, CAI J, ZHANG H, et al. VisPhone: Chinese named en-tity recognition model enhanced by visual and phonetic features[J]. Information Processing & Management, 2023, 60(3): 103314.
[15] ZHENG C, CAI Y, XU J, et al. A boundary-aware neural model for nested named entity recognition[C]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP). Stroudsburg: ACL, 2019: 357-366.
[16] LI F, WANG Z, HUI S C, et al. Modularized interaction network for named entity recognition[C]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). 2021: 200-209.
[17] SU J, MURTADHA A, PAN S, et al. Global pointer: Novel efficient span-based approach for named entity recognition[J]. arXiv preprint arXiv:2208.03054, 2022.
[18] HAN D, WANG Z, LI Y, et al. Segmentation-aware relational graph convolutional network with multi-layer CRF for nested named entity recognition[J]. Complex & Intelligent Systems, 2024, 10(6): 7893-7905.
[19] YU J, BOHENT B, POESIO M. Named entity recognition as dependency parsing[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2020: 6470-6476.
[20] LI F, LIN Z C, ZHANG M, et al. A Span-Based Model for Joint Overlapped and Discontinuous Named Entity Recognition[C]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). 2021: 4814-4828.
[21] ZHANG W, LIN H, HAN X, et al. De-biasing distantly supervised named entity recognition via causal intervention[C]// Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). Stroudsburg: ACL, 2021: 4803-4813.
[22] LI Z, CAO S, ZHAI M, et al. Multi-level semantic enhancement based on self-distillation BERT for Chinese named entity recognition[J]. Neurocomputing, 2024, 586: 127637.
[23] GUI T, MA R, ZHANG Q, et al. CNN-Based Chinese NER with Lexicon Rethinking[C]//ijcai. 2019: 4982-4988.
[24] LIU W, XU T, XU Q, et al. An encoding strategy based word-character LSTM for Chinese NER[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers). 2019: 2379-2389.
[25] LI J, FEI H, LIU J, et al. Unified named entity recognition as word-word relation classification[C]//Proceedings of the AAAI conference on artificial intelligence. 2022, 36(10): 10965-10973.
[26] LIU J, JI D, LI J, et al. TOE: A grid-tagging discontinuous NER model enhanced by embedding tag/word relations and more fine-grained tags[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2022, 31: 177-187.